

Ierarhizarea sustenabilității energetice a clădirilor


*Sistem automatizat de analiza a potențialului fotovoltaic prin modele avansate
de Deep Learning si Computer Vision*

Autor: Teodorescu Luca-Nicolae, student in anul I, Facultatea de Matematică si Informatică
Profesor coordonator: Conf. Dr. Alexe Bogdan

Cerințele si obiectivele proiectului

- Descriere generală: Dezvoltarea unui program software capabil să automatizeze procesul de selecție și clasificare a clădirilor optime pentru instalarea sistemelor de panouri fotovoltaice, utilizând tehnici de preprocesare a imaginilor satelitare.
- Obiective:
 - Segmentarea automată a acoperișurilor clădirilor din imagini satelitare pentru izolarea amprentei utile.
 - Estimarea potențialului fotovoltaic prin calcularea exactă a suprafeței utile disponibile pe acoperiș.
 - Analiza dinamica a umbrelor si a radiației, luând in calcul reliefurile si umbra generată de clădirile mai înalte din vecinătate.
 - Ierarhizarea si crearea unui clasament final al clădirilor in funcție de costul estimat al investiției si de eficiența panourilor montate.

Arhitectura soluției





Arhitectura soluției

- Abordarea generală: Utilizarea a doua modele paralele bazate pe arhitectura Transformer pentru extragerea caracteristicilor vizuale din imaginile satelitare.
- Segmentarea acoperișurilor: Antrenarea primului model Segformer dedicat identificării și izolării automate a geometriei acoperișurilor clădirilor.
- Segmentarea umbrelor: Antrenarea unui al doilea model Segformer, specializat în detecția dinamică a umbrelor formate pe sol sau pe alte structuri.
- Fuziunea măștilor(Suprapunerea):
 - Prezicerea celor doua măști segmentate pentru fiecare imagine satelitare procesată.
 - Suprapunerea geometrică a măștilor pentru a izola și evidenția direct pe suprafața fiecărui acoperiș doua zone critice: zona umbrită (background) și zona neumbrită (foreground).
- Numărarea componentelor: Utilizarea algoritmului Depth-First-Search pentru a contoriza cu precizie pixelii din masca binară corespunzător fiecărei clădiri individuale în spațiul 2D.
- Analiza radiației solare: Evaluarea calitativă a radiației prin analizarea directă a intensității pixelilor din interiorul zonelor identificate ca foreground.


Imagine RGB



Segmentarea acoperişurilor




Segmentarea umbrelor




Imagine după fuziune











Segmentarea automată a acoperişurilor







Alegerea setului de date

- Strategie de selecție: Utilizarea a doua seturi de date de dimensiuni medii/mari independente din literatura de specialitate pentru a asigura o antrenare robustă si o validare științifică de tip Cross-Dataset.
- Setul de date principal(WHU Building Dataset):
 - Specific: Imagini aeriene cu un focus clar pe amprenta clădirilor si pe delimitări curate.
 - Rol in proiect: Utilizat pentru învățarea inițială si înțelegerea riguroasă a caracteristicilor geometrice si a formelor acoperişurilor.
 - Dimensiune: Imagini standardizate la rezoluția de 512 x 512 pixeli, ideale pentru o optimizare stabilă a rețelei.
- Setul de date secundar(Inria Aerial Image Labeling):
 - Specific: Imagini la rezoluții de 5000 x 5000 pixeli, caracterizate printr-o densitate urbană extrem de ridicată si zone foarte aglomerate.
 - Dimensiunea de lucru: Pentru a putea fi procesate de model, imaginile au fost esantionate controlat la dimensiunea de 512x512 pixeli.
 - Rol in proiect: Utilizat pentru o putere mai mare de generalizare si pentru situații de densitate urbană.
 - Dimenisune: Imagini standardizate la rezoluție de 5000 x 5000 pixeli.

Date de antrenare WHU Building Dataset



Date de antrenare Inria Aerial Image Labeling



Evaluare Zero-Shot si selecția arhitecturii

- Experimentul Zero-Shot: Testarea modelelor brute NVIDIA SegFormer direct pe imaginile satelitare din setul de date WHU Building Dataset, fără antrenare prealabilă pe clădiri.
- Justificarea eliminării B1: Versiunea B1 este matematic prea simplă pentru a procesa detalii precum clădiri alipite.
- Decizia de selecție:
 - B2: Ales ca model de control datorită vitezei mari de procesare
 - B3: Ales ca model principal datorită capacității de generalizare


NVIDIA SegFormer B1	NVIDIA SegFormer B2	NVIDIA Segformer B3
mIoU: 0.1377	mIoU: 0.3961	mIoU: 0.2639

Performanta modelelor individuale: B2 vs B3

- Structura setului de date:
 - Pregatirea datelor: Setul de date WHU Building Dataset a fost utilizat in forma sa nativă.
 - Volumul de date: Lotul de antrenare a cuprins un total de 5732 de imagini satelitare, oferind o bază statistică suficient de mare pentru stabilizarea rețelelor.
- Hyperparametrii de antrenare:
 - Numar de epoci: Ambele modele au fost antrenate pe parcursul a 10 epoci.
 - Optimizator: S-a utilizat AdamW, configurat cu un learning-rate initial de $6e(-5)$ pentru a preveni deviațiile matematice bruște.
 - Functia de loss: S-a aplicat Binary Cross-Entropy Loss, strict pentru clasificare binară la nivel de pixel (Foreground vs Background).
 - Mediu de rulare: Procesul de învățare a fost executat integral in Google Colab, utilizând accelerare hardware pe GPU-ul A100.
- Setul de date de test integrat in WHU Building Dataset: B2 obtine mIoU de 0.84, B3 obtine mIoU de 0.86.

Fine-tuning pe Inria Aerial Image Labeling

- Justificare: Imaginile de antrenare din WHU Building Dataset nu includ contexte nefavorabile, precum parcări, autostrăzi, case acoperite de copaci sau densitate urbană mare.
- Dimensiune nativă: 5000 x 5000 de pixeli
- Procesare: Divizare în tile-uri de 512 x 512 pixeli, folosind un stride de 32 pixeli



Arhitectura de tip Ansamblu (Ensamble)


- Modele utilizate: Cel antrenat pe WHU Building Dataset si cel antrenat pe ambele modele.
- Concept: Structura decizională de tip Soft Voting la nivel de pixel.
- Combinarea modelelor:
 - Modelul antrenat pe WHU (pondere 40%), folosit pentru margini clare si detalii geometrice.
 - Modelul antrenat pe ambele seturi de date (pondere 60%), pentru zone urbane dense.
- Ansamblul asigura robustețe.

Cross-Dataset Validation	Model antrenat pe WHU	Model antrenat pe ambele seturi de date	Ensamble
Benchmark: mIoU	0.58 pe Inria	0.78 pe WHU	0.83 pe Inria 0.81 pe WHU

Segmentarea automată a umbrelor

- Set de date utilizat: S-EO Shadow Detection.
- Continut: 514 perechi de imagini (RGB + Masca).
- Obiectiv: Izolarea semnăturii spectrale a umbrei.
- Provocare: Diferențierea umbrelor de asfalt sau vegetație.
- Antrenare:
 - Model utilizat: Segformer B3.
 - Au fost utilizate 4 canale de input: RGB + Imaginea care reprezintă segmentarea acoperișurilor.
 - Aceasta abordare a ajutat modelul să identifice mai bine umbrele aflate în apropierea clădirilor.





Ansamblu




Fuziunea măștilor


- Input: Masca binară de acoperișuri + masca binară de umbre
- Regula de fuziune pentru imaginea de output:
 - Pixel negru: Rămâne negru dacă era clasificat negru în imaginea cu acoperișuri.
 - Pixel alb: Dacă este alb în ambele imagini de input.
 - Pixel roșu: Dacă este alb în prima imagine de input, și negru în a doua.




Segmentare umbre




Segmentare acoperișuri



Imagine fuzionata



Future Work



- Monitorizarea temporală: Procesarea aceleiași imagini satelitare, fotografiată secvențial la intervale fixe de 30 de minute, pe parcursul unei zile întregi.
- Extragerea metricilor per clădire: Monitorizarea evoluției fiecărei case de-a lungul zilei pentru a determina numărul exact de pixeli din Foreground și variația intensității lor luminoase.
- Modelarea matematică a producției: Aproximarea unei funcții continue prin tehnici de regresie care să unească toate punctele de date colectate pe parcursul zilei.
- Calculul energiei totale generate: Calcularea ariei de sub graficul funcției prin integrare numerică, oferind valoarea finală a energiei produse.